

通信感知一体化（ISAC）

ISAC基本思想理解

基础通信观测模型：从 $Y = HX + N$ 到 CSI

频域基带模型（统一入口）

通信系统在某一时刻、某一频率（或子载波）上可以抽象为：

$$Y(t, f) = H(t, f)X(t, f) + N(t, f)$$

- $X(t, f)$ ：发射信号（导频/数据）
- $Y(t, f)$ ：接收信号
- $H(t, f)$ ：信道响应（在 WiFi 中常以 CSI 形式获取）
- $N(t, f)$ ：噪声项

ISAC 的核心：把 $H(t, f)$ 从“需要消除的变量”变成“需要解释的观测”。

通信感知统一建模到底要解决什么？

在传统通信中：

- 信道 $H(t, f)$ 是需要估计并“抵消/均衡”的对象；
- 目标是可靠恢复发射符号 X 。

在 ISAC 中：

- 信道变化本身承载环境信息；
- 目标是从 $H(t, f)$ 的变化中反推环境状态、人体状态、目标运动、呼吸等参数。

ISAC 中通信与感知的关系

通信感知一体化（Integrated Sensing and Communication, ISAC）的核心思想在于通信与感知形成了双向互促的闭环，具体体现为两个方向：

- **通信辅助感知（Communication-Aided Sensing, CAS）**：利用通信波形、阵列和网络完成感知任务；
- **感知辅助通信（Sensing-Aided Communication, SAC）**：借助感知获取的环境信息反向优化通信决策。

二者的本质区别在于**信息流向**：

- 在 CAS 中，通信是“信息源”，感知是“信息消费者”；
- 在 SAC 中，感知成为“决策依据”，通信成为“受控系统”。

这一区分决定了 ISAC 是“顺带感知”，还是“感知驱动通信”。

ISAC 中通信与感知的权衡

资源竞争与协作

ISAC 系统面临的**主要挑战**之一是 **通信与感知之间的资源竞争**，尤其是在有限频谱、硬件和信号带宽的情况下。

- **频谱共享**：通信与感知共用相同的频谱资源，如何在保证 **通信速率** 的同时，最大化 **感知精度**？
- **功率分配**：通信与感知所需的发射功率不同，如何有效分配功率，以既保证通信质量，又提供足够的感知灵敏度？

评估通信与感知的性能指标

通信性能指标

1、数据率（Data Rate）

数据率是衡量通信系统性能的核心指标之一，通常用于描述单位时间内传输的数据量。

- **峰值数据率（Peak Data Rate）**：系统能提供的最大数据传输速率。
- **用户体验数据率（User Experience Data Rate）**：在实际使用场景下的平均数据传输速率。

对于 ISAC 系统，数据率的高低直接影响通信系统的响应能力，特别是在车联网和智能家居等低时延应用场景中。

2、误码率（Bit Error Rate, BER）

误码率（BER）是衡量通信系统可靠性的一个重要指标，定义为接收数据中错误比特占总比特的比例。

$$BER = \frac{\text{错误比特数}}{\text{总比特数}}$$

在 ISAC 系统中，BER 直接影响到 **数据传输的准确性**，是评估 **通信信号质量** 和 **系统稳定性** 的重要参数。

3、信噪比（SNR）与信干噪比（SINR）

信噪比（SNR）和信干噪比（SINR）是无线通信中常用的性能指标，尤其在 ISAC 系统中，SNR 和 SINR 不仅影响通信性能，也间接影响感知系统的准确性。

- SNR（Signal-to-Noise Ratio）**：信号功率与噪声功率的比值，衡量通信信号的强度。
- SINR（Signal-to-Interference-plus-Noise Ratio）**：信号功率与干扰加噪声功率的比值，衡量系统的信号质量。

$$SNR = \frac{\text{信号功率}}{\text{噪声功率}}, \quad SINR = \frac{\text{信号功率}}{\text{干扰功率} + \text{噪声功率}}$$

SINR 主要影响 ISAC 中通信和感知模块的 **性能与效率**，是评估 **系统可用性** 的关键指标。

感知性能指标

1、检测概率（Pd）

检测概率（Pd）是衡量感知系统**正确检测目标**的能力。它是感知系统的核心性能指标之一，特别在 **目标检测** 任务中，Pd 直接影响检测的准确性。

$$P_d = \frac{\text{正确检测目标的次数}}{\text{总目标检测次数}}$$

在 ISAC 系统中，高 Pd 需要高 SNR 和 SINR，而这又与通信性能紧密相关，因此，**Pd 是通信与感知协同优化的关键**。

2、误差估计（MSE）

均方误差（MSE）是衡量感知系统**估计精度**的标准指标，广泛应用于 **定位、速度估计** 等任务中。MSE 越小，说明感知系统越准确。

公式：

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (\hat{\theta}_i - \theta_i)^2$$

其中：

- $\hat{\theta}_i$ ：第 i 次估计值
- θ_i ：真实值

ISAC 系统中，MSE 的优化通常通过改进 **信号处理** 和 **统计建模** 来实现。

3、Cramér-Rao Lower Bound（CRLB）

CRLB 是统计估计理论中的一个重要概念，用于表示任何无偏估计器在给定信号的情况下所能达到的 **最小估计误差**。

$$\text{CRLB} = \frac{1}{\mathbb{I}(\theta)}$$

其中：

- $\mathbb{I}(\theta)$ ：**费舍尔信息矩阵**，衡量系统对于参数 θ 的敏感度。

在 ISAC 系统中，CRLB 用于分析 **参数估计精度**，并作为通信和感知任务优化的理论下限。

4、互信息（Mutual Information, MI）

互信息在信号/感知里到底衡量什么？

互信息定义为：

$$I(X; Y) = H(X) - H(X|Y)$$

在感知问题中，你可以这样映射：

- X ：你关心的**真实状态**
 - 人的位置
 - 人的动作类别
 - 呼吸信号
- Y ：你观测到的 **CSI / 加密 CSI**

于是：

互信息衡量的是：CSI 里到底“包含了多少关于人体状态的信息”。

这是一个**极其“干净”**的隐私指标：

- $I(X; Y)$ 越大 $\rightarrow$ 泄露越多隐私
- $I(X; Y)$ 越小 $\rightarrow$ 攻击者能学到的越少

联系与沟通：MI 与其他指标的关系

MI 厉害的地方在于它和其他核心指标是**打通**的：

1. MI 与 CRLB 的关联：

根据信息论中的 **De Bruijn 恒等式**，互信息对信号参数的导数与 CRLB（费舍尔信息量）有着直接的数学联系。简单说：MI 越大，理论上能达到的 CRLB 就越小（估计越准）。

2. MI 与检测概率 (P_d):

MI 越高，说明信号中目标特征越明显，分类器（如 AI 模型）的准确率和检测概率自然就越高。

代价指标：效率度量指标

频谱效率（SE）与能量效率（EE）

频谱效率（Spectral Efficiency, SE）

频谱效率是衡量单位频带宽度内，传输速率的能力。频谱效率越高，说明系统利用频谱资源的能力越强，是无线通信系统中一个核心的优化指标。

$$SE = \frac{\text{数据率}}{\text{带宽}}$$

在 ISAC 系统中，频谱效率直接关系到 **通信任务的执行能力**，同时，随着感知任务的增加，**频谱共享和资源分配**也会成为提升 SE 的关键。

能量效率（Energy Efficiency, EE）

能量效率是衡量单位能量消耗所能传输的比特数。在 ISAC 系统中，低功耗设计对于实现长期部署和低成本运作非常重要。

$$EE = \frac{\text{传输比特数}}{\text{消耗能量}}$$

在 ISAC 中，提高 **感知精度** 与 **通信能力** 的同时，能量效率也需要被优化，以实现 **绿色通信与感知系统**。

任务：如何在保持高 SE 和 EE 的前提下提高感知性能

CSI的感知与建模

CSI 的多径叠加模型（WIFI感知论文）

物理全集 (The General Model)

是最经典的信道频率响应（CFR）模型：

在多径丰富的室内环境，可以给出给出经典 CSI 多径叠加模型：

$$H(t, f) = \sum_{l=1}^L a_l(t) e^{-j2\pi f\tau_l(t)}$$

其中：

- L ：多径分量（MPC）数量
- $a_l(t)$ ：第 l 条路径的复幅度
- $\tau_l(t)$ ：传播时延（与路径长度相关）

《WiResP: A Robust WiFi-Based Respiration Monitoring via Spectrum Enhancement》中也采用了同类建模，并进一步指出：不同多径对环境变化敏感程度不同（“location-dependent sensitivity”），这也是子载波、链路组合、统计增强等技术得以实现的根本原因。

[!NOTE]

针对文献WiShield: Privacy against Wi-Fi Human Tracking具体分析

CSI 的 OFDM 多径模型

当 Tx 在第 n 个子载波、包序号 m 发送 LTS，Rx 得到 CSI $h_{n,m}$ 。论文给出模型：

$$h_{n,m} = \sum_{k=1}^K \alpha_{n,m,k} e^{-j2\pi(f_c + n\Delta f)\tau_{m,k}} \tag{1}$$

解释：

- K ：多径条数
- $\alpha_{n,m,k}$ ：第 k 条径的复衰落系数（幅度+相位）
- f_c ：载频
- Δf ：子载波间隔
- $\tau_{m,k}$ ：第 k 条径传播时延（随时间可变）
- 文中进一步把时延拆为：
 - 静态反射产生的 τ_k^S
 - 运动目标导致的动态分量 $\tau_{m,k}^D$

这条公式是 Wi-Fi 感知/定位一切算法的根：AoA/ToF/DFS 本质上都是从 CSI 的相位/频率/时间变化里“反演”出来的。

感知专用拆解 (The Sensing-Oriented Model)

静态路径 + 动态路径分解（把“感知”数学化）：CSI 的静态/动态分解（Classic in Wi-Fi sensing）

相关研究将 CSI 显式拆成 **静态路径** 与 **动态路径**：

$$H(t, f) = \underbrace{H_{\text{static}}(f)}_{\text{静态路径}} + \underbrace{\sum_{i \in \Omega_d(t)} a_i(t) e^{-j2\pi f \tau_i(t)}}_{\text{动态路径}} + n(t, f)$$

其中：

- 静态路径：墙/家具等不动散射体（短时间内近似常量）
- 动态路径：人体/手势/呼吸等引发的时变散射

出自文献《WiResP: A Robust WiFi-Based Respiration Monitoring via Spectrum Enhancement》

这条分解等价于 ISAC 里常说的“环境参数 → 信道变化”：

- 感知信息主要存在于 $H_{\text{dynamic}}(t, f)$ 。

[!NOTE]

针对文献WiShield: Privacy against Wi-Fi Human Tracking具体分析

论文先在“多径时延”层面拆成静态 + 动态（从 Eq.(1) 开始）

论文对第 m 个数据包、第 n 个子载波的 CSI 写成（Eq. (1) 的核心含义）：

$$h_{n,m} = \sum_{k=1}^K \alpha_{n,m,k} e^{-j2\pi(f_c + n\Delta f)\tau_{m,k}}$$

然后关键一句话：每条路径的时延 $\tau_{m,k}$ 被拆为两部分：

$$\tau_{m,k} = \tau_k^S + \tau_{m,k}^D$$

- τ_k^S ：静态时延（来自墙、桌子等“不会动”的反射体）——对时间 m 基本不变
- $\tau_{m,k}^D$ ：动态时延（由人体运动导致的反射/散射路径变化）——随时间 m 变化

这一步其实就在告诉你：

“能感知人”并不是因为 CSI 本身神秘，而是因为 CSI 里有一部分随人的运动而变化的动态多径结构。

把“路径集合”分成动态路径 K_D 和静态路径 K_S

论文随后直接给出“动态分量”和“静态分量”的表达 (Eq. (6)、(7))。注意这里作者为了讲清概念，把频域子载波 n 的细节先省略了 (写成按包序号 m 的一条 CSI 时序)，核心是“按路径类型求和”：

动态分量 (human-related / motion-induced)

$$h_m^D = \sum_{k \in K_D} \alpha_{m,k}^D e^{-j2\pi f_c \tau_k^D} \quad (6)$$

静态分量 (environment reflection)

$$h_m^S = \sum_{k \in K_S} \alpha_{m,k}^S e^{-j2\pi f_c \tau_k^S} \quad (7)$$

你可以这样理解：

- K_S ：所有“背景环境反射”的路径集合（静态墙体/家具等）
- K_D ：所有“与人体相关”的路径集合（人体反射、人体引起的遮挡/多径变化等）
- 静态分量 h_m^S 通常**慢变化/近似常量**
- 动态分量 h_m^D 随动作、呼吸、走动而变化，**携带隐私信息**

论文在这一段的语气非常明确：

攻击者 (Eve) 做推断时真正“吃”的就是 h_m^D 这部分（人的动态反射/变化）。

这个分解用来定义感知质量指标（很关键）

作者马上用它定义“感知型 SNR” (Eq. (8))，用来衡量“动态信息相对静态背景/噪声有多强”：

$$\eta_S = \frac{1}{M} \sum_{m=1}^M \frac{|h_m^D|^2}{|h_m^S|^2 + \sigma^2} \quad (8)$$

这条式子在论文里的角色非常重要：

- 分子 $|h_m^D|^2$ ：**与人体相关的动态能量**
- 分母 $|h_m^S|^2 + \sigma^2$ ：**环境静态背景 + 噪声**
- η_S 越大：动态占比越大 → 感知越容易 → 攻击也越容易

然后作者指出：WiShield 会引入“加密失真”，所以仅用 η_S 不够，于是提出 SDNR (Eq. (9))，把“加密造成的失真”也放到分母里：

$$\eta_{SD} = \frac{1}{M} \sum_{m=1}^M \frac{|\hat{h}_m^D|^2}{\|\hat{h}_m - h_m\|^2 + |h_m^S|^2 + \sigma^2} \quad (9)$$

这就是论文里静态/动态分解的“落地价值”：

没有 h^D/h^S 的分解，你就没法明确写出“感知信息（动态）/背景干扰（静态）/噪声/加密失真”之间的量化关系。

CSI 的获取与估计：基于 LTS 的零迫信道估计

基于 LTS 的零迫（Zero-Forcing, ZF）估计，正是目前商用 WiFi 芯片获取 CSI 的核心原理。

1. 什么是 LTS？

在 WiFi 数据帧的头部（Preamble），有一段特殊信号叫 LTS (Long Training Symbol, 长训练符号)。

- 它是已知的：发射端和接收端都提前存好了这段信号的“标准样张”。
- 它是标准化的：在 802.11 协议中，LTS 在频域上的每一个子载波都有固定的值（通常是 +1 或 -1）。

2. 什么是零迫 (Zero-Forcing) 估计？

“零迫”其实数学上非常简单：直接相除。

假设在第 k 个子载波上：

- $X(k)$ 是发射端送出的 LTS 标准信号（已知）。
- $Y(k)$ 是接收端实际收到的信号（测量得到）。
- $H(k)$ 是我们要找的信道响应（CSI）。

信号传输的物理过程可以简化为：

$$Y(k) = H(k) \cdot X(k) + N(k)$$

（其中 $N(k)$ 是噪声）

零迫估计（ZF Estimation） 的逻辑就是直接忽略噪声，强行把信道“还原”出来：

$$\hat{H}(k) = \frac{Y(k)}{X(k)}$$

直观理解：如果你知道我发的是“1”，你收到了“ $0.8 + 0.2j$ ”，那么这个子载波上的 CSI 就是 $0.8 + 0.2j$ 。

3. 为什么 WiFi 芯片爱用它？

- **速度极快：**只需要一次除法（或乘法，因为 $X(k)$ 是 ± 1 ），硬件电路实现成本极低。
- **独立性：**每个子载波独立计算，非常适合 OFDM（正交频分复用）系统。

[!NOTE]

针对文献 WiShield: Privacy against Wi-Fi Human Tracking 具体分析

本质是 ZF/LS 的简化形式

论文描述 LTS 频域符号 $s_{n,m}$ ，接收为 $y_{n,m} = h_{n,m}s_{n,m}$ 。常见估计：

$$\hat{h}_{n,m} = \frac{y_{n,m}}{s_{n,m}}$$

解释：对第 m 个包、子载波 n ：

- 已知 LTS 频域符号： $s_{n,m}$ （标准定义，通常每个子载波是 ± 1 或 0 的已知序列）
- 接收频域符号： $y_{n,m}$
- 频域信道： $h_{n,m}$
- 噪声： $w_{n,m}$

OFDM 频域模型（论文就是靠这个做推导/解释，并且由于是零迫因此忽略了噪声）：

$$y_{n,m} = h_{n,m} s_{n,m} + w_{n,m}$$

关键点：因为 LTS 可被窃听，攻击者也能做同样操作得到 CSI。

[!CAUTION]

现代 CSI 估计的进阶手段

虽然 LTS + 零迫是基础，但在 2026 年的现代 WiFi 感知和通信中，纯粹的零迫估计因为对噪声太敏感，已经被多种高级手段补充：

1. LMMSE（线性最小均方误差）

零迫估计在信号很弱（低 SNR）时，会把噪声也成倍放大。**LMMSE** 利用了信道的统计特性（比如噪声功率），在估计时做了一个“平滑”，让结果更接近真实物理信道。

- **优点：**抗噪性比零迫强得多。
- **缺点：**计算量大，涉及矩阵运算。

2. 压缩感知与 AI 估计 (CSI Extrapolation)

随着 **WiFi 7/8** 的普及，子载波数目巨大（如 320MHz 带宽下有上千个子载波），全量测量开销太大。

- **AI 驱动：**利用神经网络学习信道在时间和频率上的相关性。即使只收到了一部分子载波的信息，AI 也能“脑补”出完整的全频带 CSI。
- **6G 前瞻技术：**目前研究的热点是通过极少量的导频（Pilots）结合深度学习（如 CsiNet）来预测高动态环境下的 CSI。

3. 跨帧平滑处理 (Phase Sanitization)

由于商用网卡硬件时钟的不完美，原始算出的 CSI 往往带有严重的**相位偏移（Phase Drift）**。

- **现行手段：**现在的估计不再只看单帧，而是通过线性拟合或多帧平均来消除取样频率偏移（SFO）和符号定时偏移（STO），让 CSI 变得“纯净”可用于感知。

特征提取与数据预处理（感知第一步）（域无关处理）

统计电磁（Statistical EM）建模

统计电磁建模的核心就是把多径当作“虚拟传感器阵列”，每个散射体都是“虚拟天线 / 虚拟发射源”

相关研究中用非常直接的语言把统计电磁模型讲清楚：

每个散射体可视作虚拟天线，将接收到的电磁波向各方向再辐射，最终在接收端叠加。

并把信号拆为静态散射体与动态散射体之和：

$$s(t, f) = \sum_{k \in S(t)} s_k(t, f) + \sum_{m \in D(t)} s_m(t, f)$$

短时间内静态集合变化小，因此静态项可近似常量：

$$s(t, f) \approx E_s(f) + \sum_{m \in \mathcal{D}(t)} s_m(t, f)$$

这与上面的 CSI 静/动分解在思想上一致。

出自文献《WiCPD: Wireless Child Presence Detection System for Smart Cars》

算法实现：静态消除（Mean Subtraction）是“把通信信道变成感知信号”的第一步

相关研究明确指出：短时间内静态分量可认为稳定，从而可通过**均值消除**去掉静态项：

$$\tilde{H}(t, f) = H(t, f) - \mathbb{E}_t[H(t, f)]$$

直观解释：

- 均值消除后得到的 $\tilde{H}(t, f)$ 主要反映动态散射体引起的变化
- 这一步把“通信测得的 CSI”转化为“感知可用的动态信道扰动”

出自文献《WiResP: A Robust WiFi-Based Respiration Monitoring via Spectrum Enhancement》
《GWrite: Enabling Through-the-Wall Gesture Writing Recognition Using WiFi》。这也是 GWrite 技术在 through-the-wall 场景中强调“移除静态环境贡献”的核心原因之一。

统一形式：CSI 的“静态散射体集合 + 动态散射体集合”分解

此外，还可以给出同样的电磁叠加分解（更贴近 CSI 形式）：

$$H(t, f) = \sum_{i \in \Omega_s(t)} H_i(t, f) + \sum_{j \in \Omega_d(t)} H_j(t, f) + \varepsilon(t, f)$$

关键解释（ISAC 统一建模的核心点）：

- $\Omega_s(t)$ ：静态散射体集合（墙/地面/固定家具）
- $\Omega_d(t)$ ：动态散射体集合（人体/宠物/机器人/呼吸胸腔）
- 每个散射体贡献一个“虚拟发射源”的电磁叠加项（把室内多径理解为巨量虚拟传感器）

[!NOTE]

论文XFall: Domain Adaptive Wi-Fi-based Fall Detection with Cross-Modal Supervision中

SDP（速度分布谱）的理论基础与公式推导

这一部分是全文“物理/信号处理”最关键的贡献点：用统计电磁场模型，把 CSI 的自相关结构映射到“速度分布”。

室内富散射环境建模（Rich scattering）

室内可看作富散射腔体：墙、家具、人体各部位都作为散射体（scatterers）。接收端电场可分解为静态散射 + 动态散射：

(1) 电场分解

$$\vec{E}_{Rx}(t, f) = \sum_{\alpha \in \Omega_s(t)} \vec{E}_{\alpha}(t, f) + \sum_{\beta \in \Omega_d(t)} \vec{E}_{\beta}(t, f)$$

- Ω_s ：静态散射体集合（墙、固定家具...）
- Ω_d ：动态散射体集合（人体运动部位...）
- 关键：跌倒属于强动态事件，应主要体现在 Ω_d 上。

4.2 单个动态散射体的电场与速度关系

论文从电磁波入射角谱积分写出单个散射体 α 的贡献：

(2) 单散射体电场

$$\vec{E}_{\alpha}(t, f) = \int_0^{2\pi} \int_0^{\pi} \vec{A}(\phi, \theta) \exp(-j \vec{k} \cdot \vec{v}_{\alpha} t) \sin \phi d\phi d\theta$$

- $\vec{A}(\phi, \theta)$ ：角谱（angular spectrum），描述来自方向 (ϕ, θ) 的入射分量
- $\vec{k}$ ：波数向量（与频率相关）
- $\vec{v}_{\alpha}$ ：散射体速度
- 核心含义：速度通过相位项 $\exp(-j \vec{k} \cdot \vec{v} t)$ 影响电场的时间相关性。

4.3 统计电场理论：把不可解析的室内传播变成统计可推断

室内传播难以确定性建模（你不知道每次反射路径与角谱），所以改用**统计模型**：把电场视为大量随机相位/极化波的叠加，得到关键性质：

- $\vec{A}(\phi, \theta)$ 可视为圆对称复高斯随机变量（circularly symmetric complex Gaussian）
- 不同散射体、不同时间的分量近似不相关（uncorrelated）
- 于是电场可近似为平稳随机过程，可用**自相关函数（ACF）**见后描述动态信息。

二阶统计量：ACF(自相关函数) 与 TRRS（时间反演）

- WiResP/WiCPD/Wi-MoID等技术（以及多数 WiFi 感知）用 **ACF**
- GWrite 技术用 **TRRS**（时间反转相似度）

为什么需要二阶统计？

在 ISAC 系统中，通信和感知共享同一信号和频谱资源。在多径强、目标反射弱的场景（如 through-the-wall、车内、多人、微动），一阶变化（如幅度差分）容易被多径相消或噪声淹没，二阶统计可以把“分布在各处的动态散射体贡献”**构造**成“**相干的统计量**”。

统计特征处理技术在以下方面扮演着至关重要的角色：

- **信号增强**：通过提取 **信道特征**（如 ACF、MRC 等），使感知信号更具鲁棒性。
- **噪声消除**：去除静态噪声和干扰，使动态目标（如人、物体、呼吸）更易被捕捉。
- **目标分离**：在多人/多物场景中，基于运动统计特征分离出每个目标的运动轨迹。

这些技术直接支撑了 **WiFi 呼吸监测、手势识别、多人感知** 等任务。

《WiCPD: Wireless Child Presence Detection System for Smart Cars》中指出：传统 variation-based 方法里不同位置动态散射体可能“相消”，而统计 EM + ACF 使所有动态散射体“构造性贡献”。

ACF

自相关函数（ACF）是 **时间序列分析** 中常用的统计工具。在 ISAC 中，ACF 用于分析 CSI 随时间变化的特性，从而提取出与感知任务（如运动、呼吸）相关的统计特征。WiResP 的系统流程明确把 **ACF** 作为关键中间量，用于运动检测与呼吸估计

Wi-MoID技术更进一步说明：通过 CSI 的 ACF 可实现：

- 运动检测
- 速度估计
- 提取可解释特征，并强调这些特征能做到环境/位置/方向独立

ACF 的本质是计算信号与自身在不同时间点的相似度。这个统计量能够捕捉到 **周期性运动**（如呼吸或行走）的特征。

- ACF 在 ISAC 中的应用
 - **呼吸监测：**
 - 通过 ACF，WiResP 技术能够从微弱的呼吸信号中提取出周期性变化，从而估计呼吸频率。
 - **运动检测：**
 - ACF 可以应用在 Wi-MoID 技术中，实现检测并提取 **人的运动特征**，如步伐、速度等。
 - **噪声抑制：**
 - 由于 ACF 只关注 **时间上的相关性**，它能有效去除由静态物体（如墙壁、家具）引起的噪声，从而专注于动态目标。
- ACF 的优势
 - **抗干扰能力：**由于 ACF 基于信号的 **自相关性**，它能有效应对信号中的噪声与环境干扰。
 - **鲁棒性强：**即使在复杂环境下，ACF 也能有效提取与目标运动相关的信号特征。

[!NOTE]

论文XFall: Domain Adaptive Wi-Fi-based Fall Detection with Cross-Modal Supervision中

用 ACF（自相关）把 Wi-Fi 信号中的复杂多径细节“统计化”，从而得到与人体运动速度分布直接相关的结构；再把这种相关结构做成二维图（SDP），作为更“域无关”的特征输入模型。

ACF 和 SDP 的关系

ACF 是“速度分布”的载体

- 在统计电磁场模型下，一个运动散射体（身体某个部位）会让电场的时间相关性呈现 **sinc** 形式：

$$\frac{\sin(kv\tau)}{kv\tau}$$

- 多个身体部位同时运动（不同速度）时，整体相关性变成多个 sinc 的加权和：

$$\rho(\tau) \approx \sum_{\alpha} w_{\alpha} \text{sinc}(kv_{\alpha}\tau)$$

- 所以 **ACF** 的“形状随 τ 如何变化”本质上编码了“有哪些速度、各自占多少权重”（即速度分布）。

SDP 是“把 ACF 在时间上滚动成一幅图”

- ACF 本来是“ τ 轴上的一条曲线（每个时刻一条）”
- 但跌倒是一个过程，速度分布会随时间变：
 - 跌倒前：低速/平稳
 - 失衡/下落：速度分布变宽，高速成分变强
 - 撞击后：速度成分变化
- 因此论文把每个时间片的 ACF（随 τ 的曲线）当作一列，沿时间拼起来：

$$\underbrace{(\text{纵轴: } \tau)}_{\text{表示速度分布结构}} \times \underbrace{(\text{横轴: 时间 } t)}_{\text{表示过程演化}} \Rightarrow \text{SDP}$$

所以：SDP = ACF 的“时间序列可视化/谱化”结果。

ACF->SDP

定义单个散射体的电场 ACF

$$\rho_{\vec{E}_{\alpha}}(\tau, f) = \frac{\langle \vec{E}_{\alpha}(t, f), \vec{E}_{\alpha}(t + \tau, f) \rangle}{\sqrt{\|\vec{E}_{\alpha}(t, f)\|^2 \|\vec{E}_{\alpha}(t + \tau, f)\|^2}}$$

- 这是“规范化自相关”，输出范围稳定（不受绝对幅度影响）
- τ 越大，相似度越低/越振荡，反映运动造成的相位变化更快

统计电磁理论给出“ACF 与速度的显式关系”

$$\langle \vec{E}_{\alpha}(t, f), \vec{E}_{\alpha}(t + \tau, f) \rangle = E_{\alpha}^2(f) \frac{\sin(kv_{\alpha}\tau)}{kv_{\alpha}\tau}$$

它在讲什么：

- 一个以速度 v_{α} 运动的散射体会产生 **sinc 形状的相关性**
- v_{α} 越大， $\sin(kv\tau)/(kv\tau)$ 随 τ 的变化越快 → 相关性更快衰减/振荡更密

关键直觉：速度越快 → 信号变化越快 → “隔一段时间再看就不那么像了” (ACF 下降更快)。

多个动态散射体叠加

$$\rho_{\vec{E}_{Rx}}(\tau, f) = \frac{1}{\sum_{\beta \in \Omega_d} E_{\beta}^2(f)} \sum_{\alpha \in \Omega_d} E_{\alpha}^2(f) \frac{\sin(kv_{\alpha}\tau)}{kv_{\alpha}\tau}$$

- 接收端看到的是“所有运动部位”的叠加
- 因此整体 ACF 是不同速度的 sinc 基函数的加权和
- 权重 $\propto E_{\alpha}^2(f)$ (该部位散射能量贡献越大，影响越大)

这一步把“单一速度”扩展成“**速度分布**”：

ACF = 速度分布经过 sinc 映射后的加权叠加。

从电场换成 CSI

因为硬件拿不到 $\vec{E}$ ，但拿得到 CSI H 。

关键点：

- 训练字段 X 可视为常数，因此：

$$|H(t, f)| \propto \|\vec{E}_{Rx}(t, f)\|$$

- 所以用 CSI 也能得到类似的相关结构：

$$\rho_H(\tau, f) = \frac{\text{cov}(H(t, f), H(t + \tau, f))}{\text{cov}(H(t, f), H(t, f))} \approx \sum_{\alpha \in \Omega_d} w_{\alpha} \text{sinc}(kv_{\alpha}\tau)$$

意义：

- 你不需要知道复杂的多径路径
- 只要算 CSI 的 ACF，就能得到“速度分布”的统计指纹

把 CSI 的 ACF 做成 SDP

论文工程化做法是：

(9) 计算离散化的 ACF（对每个子载波、每个时间位置、每个时延）

$$\rho(n, i, j) = \frac{|H(t_i, f_j)H^*(t_i - n\Delta T, f_j)|}{|H(t_i, f_j)| |H(t_i - n\Delta T, f_j)|}$$

- $n\Delta T$ 是时延 (lag)
- i 是时间滑动位置 (当前时刻)
- j 是子载波

(10) 子载波融合 + 归一化，得到 SDP 的一系列

$$S(n, i) = \frac{\sum_{j=1}^{N_S} \rho(n, i, j) / N_S}{\sum_{n=1}^{N_\Delta} \rho(n, i, j)}$$

- 对子载波平均：减少频率选择性衰落的偶然性
- 对 n 归一化：把每个时刻的 ACF 变成“分布形态”(更可比、更稳定)
- 最终 S 是二维矩阵：
 - 纵轴 n (对应不同 lag τ) → 反映速度分布结构
 - 横轴 i (时间推进) → 反映跌倒过程演化

TRRS

时间反转 (TR) 是一个物理现象，通过将信号反向传播，可以使多个反射的信号聚焦到一个点上，用来刻画时间反转聚焦效应。

ISAC 中，TR 的核心思想是 **通过时间反转来增强信号**，尤其在 **多径干扰** 较强的情况下，可以用来计算时间反转前后的 CSI 信号相似度，来 **提取空间聚焦信息**。

TRRS 公式为：

$$\text{TRRS}(H_1, H_2) = \frac{\left| \sum_{l=1}^L H_1(l) H_2(l)^* \right|^2}{\sum_{l=1}^L |H_1(l)|^2 \sum_{l=1}^L |H_2(l)|^2}$$

其中：

- H_1, H_2 ：时间反转前后的 CSI 信号
- L ：多径分量数量

TRRS 可以揭示出多径的 **聚焦点**，有助于对 **目标位置** 或 **距离** 的估计。

技术比较与应用场景

技术	核心功能	主要应用场景
ACF	提取周期性变化（如呼吸、步伐）	呼吸监测、运动检测
MRC	信号增强与噪声抑制	多人感知、复杂环境下的目标检测
TR / TRRS	时间反转增强信号	透过墙体的手势识别、车辆感知
运动统计	运动估计与目标分离	人体轨迹分离、人数统计

最大比合并（MRC）

最大比合并（MRC）是 **信号增强技术**，广泛应用于多天线系统中。其目的是通过结合来自不同接收链路的信号，增强信号强度，并抑制噪声和干扰。

MRC 的数学表达式为：

$$\hat{y}_{\text{MRC}} = \sum_{k=1}^N \alpha_k y_k$$

其中：

- y_k ：第 k 路接收信号
- α_k ：每路信号的加权系数（通常根据信号强度或信噪比设定）

在 ISAC 中，MRC 主要用于**增强信号的感知灵敏度**，特别是在复杂的环境中，如 **NLOS（非视距）场景、墙后目标识别、多人呼吸监测**等。

- 增强目标信号**：WiCPD技术通过 MRC 增强微弱的 **呼吸信号**，从而准确检测车内的儿童是否存在。
- 去除静态干扰**：Wi-MoID技术利用 MRC 技术增强来自 **移动目标（人或宠物）** 的信号，抑制来自静态环境的多径干扰。

MRC 的优势

- 增强感知灵敏度**：通过 MRC，能够有效提高对微弱动态信号的感知灵敏度，如人的呼吸、微位移等。
- 抗干扰能力**：在多径复杂的环境中，MRC 能通过多通道加权有效提升信号质量。

ISAC的感知执行链

检测：目标存在性检测

- ISAC 系统首先需要判断目标是否存在（如人体、物体）。
- 通过 **二元假设检验**（例如，是否有人在房间里），根据 CSI 提取的动态特征进行决策。

$$H_0 : \text{无目标}, \quad H_1 : \text{有目标}$$

估计：目标位置、速度估计

- 在确认目标存在后，需要估计目标的 **位置、速度、距离** 等参数。ISAC 系统通过 **最大似然估计**（MLE）等方法进行 **参数估计**。

$$\hat{\Theta} = \arg \max_{\Theta} \mathbb{P}(Z|\Theta)$$

分类：多类目标识别

- 对于多目标、多场景，ISAC 系统通过 **分类算法**（如 SVM、深度学习等）进行目标类别识别。比如，Wi-MoID 通过运动模式识别来区分人类和非人类目标。

雷达模型对比与系统挑战（从“通信信号”转向“物理感知”的第二步）

雷达模型

几何雷达模型

几何雷达的基本思想

传统雷达（Pulse Radar / FMCW / MIMO Radar）建立在**几何电磁传播模型**之上，其核心假设是：

目标是“可分辨的、少数的、强反射体”

典型回波模型为：

$$r(t) = \sum_{k=1}^K \alpha_k s(t - \tau_k) e^{j2\pi f_{D,k}t} + n(t)$$

其中：

- K ：目标或主要反射体数量（通常很小）
- τ_k ：传播时延（→ 距离）
- $f_{D,k}$ ：多普勒频移（→ 速度）
- α_k ：反射系数（与 RCS 有关）

几何雷达模型的关键假设

1. 路径可分辨

- 依赖超大带宽（高时间分辨率）

2. 目标反射显著

- 目标 RCS 远大于环境散射

3. 多径可忽略或可抑制

- 多径被视为杂波（clutter）

4. LOS 或弱 NLOS

- 至少存在主导路径

在这些假设下，雷达可以清晰地做：

- 距离估计（ToF）
- 速度估计（Doppler）
- 角度估计（AoA）

几何雷达的缺点：

- 天线与角度分辨率不足
 - WiFi 设备：
 - 天线数有限
 - 阵列尺寸小
 - AoA 分辨能力极弱
- 目标反射强度远小于环境散射

- 在 WiFi 感知场景中：
- 人体反射 = 弱散射
- 墙体 / 家具 = 强散射

与雷达“目标主导”的假设完全相反
目标反射信号**被淹没在强多径中**

WiCPD、WiResP 都强调：

直接使用 variation-based 或几何反射模型时，不同散射体的贡献可能相互抵消，导致感知失败。

- NLOS 成为常态而非例外
 - WiFi-ISAC 的典型场景：
 - 穿墙 (through-the-wall)
 - 室内遮挡
 - 车内复杂反射

几何模型依赖的“主反射路径”往往根本不存在

统计多径感知模型

统计多径模型的核心假设是：

不试图分离路径，而是利用“大量不可分辨多径的统计规律”

换句话说：

- 放弃单径几何解释
- 拥抱多径叠加的统计特性

在 WiFi 感知论文中，CSI 被建模为：

静态散射体集合 + 动态散射体集合（人体、手、胸腔）

- 每个散射体 → 一个“虚拟电磁源”
- 每一条多径：
 - 走过不同空间路径
 - 对环境扰动有不同敏感度
- 大量多径叠加：
 - 相当于一个**密集、无序、分布式的虚拟传感器阵列**

多径越多，感知维度越高

与雷达完全相反：多径是资源，而非噪声

短时间内静态散射体不变

- 静态路径被抑制
- 动态散射体贡献被凸显

由于单个路径不可分辨，统计模型转而使用：

- 自相关函数（ACF）
- 协方差
- 能量分布
- 频谱结构

二阶统计能：

- 抑制噪声
- 聚合多径贡献
- 把微弱运动“叠加放大”

Time Reversal 理论表明：

- 多径环境中，时间反转等价于**完美匹配滤波**
- 聚焦效果来源于**多径的相干叠加**

其统计结果呈现 **Bessel 分布**

对于雷达模型的总结

维度	几何雷达模型	统计多径模型
路径处理	分离单径	利用叠加
多径角色	干扰 / 杂波	信息 / 资源
关键维度	距离、角度、速度	统计特征
带宽需求	极高	中等
NLOS	极难	天然支持

维度	几何雷达模型	统计多径模型
WiFi 场景	不支持	支持

7 篇论文，无一采用纯几何模型，这是必然选择，而非巧合。

统计估计类 (Statistical Estimation)

有关于感知参数的估计

这些是“从 CSI 中估计参数”的经典统计路线，论文在恢复后使用：

- **MLE (Maximum Likelihood Estimation, 最大似然估计)**：把多径参数（幅度、时延 ToF、角度 AoA、多普勒 DFS）放进参数向量，通过最大化似然/最小化误差估计。
- **SAGE (Space-Alternating Generalized EM, 空间交替广义 EM)**：一种 EM 风格的迭代估计方法，把高维多径联合估计拆成“逐径/逐参数交替更新”，降低复杂度、提高可解性。

这两者在“Wi-Fi 参数反演 (AoA/ToF/DFS)”里非常典型，属于统计估计主干。

1. MLE (Maximum Likelihood Estimation, 极大似然估计)

MLE 是参数估计的“基石”和目标。

- **基本原理**：给定观测到的信号（CSI 数据），MLE 寻找一组参数 θ （包括时延 τ 、角度 ϕ 、幅度 a 等），使得产生这组观测数据的概率（似然函数）最大。
- **在感知中的应用**：
 - 对应你文档中的多径叠加模型 $H(t, f)$ ，MLE 的目标是找到那 L 条路径的最优参数，使得重建的信号与实际接收到的信号误差最小。
 - **优点**：在理论上，当噪声为高斯白噪声时，MLE 是渐进无偏的，其精度可以达到你提到的 **CRLB (理论下限)**。
 - **缺点 (挑战)**：直接计算 MLE 需要在多维空间进行网格搜索 (Grid Search)。如果你要同时估计 5 条路径，每条路径有 3 个参数，那计算量会呈指数级爆炸，硬件上几乎无法实现实时处理。

2. SAGE (Space-Alternating Generalized Expectation-maximization)

SAGE 是实现 MLE 的一种“聪明且高效”的迭代算法。

SAGE 是典型的“分而治之”策略，专门为了解决 MLE 计算量太大的问题而生。

- **核心逻辑：**
 - i. **多径拆解：**它不试图一次性估计所有 L 条路径的所有参数。
 - ii. **交替优化 (Space-Alternating)：**它每次只假设其中**一条路径**的参数是未知的，而固定其他所有路径的参数。
 - iii. **迭代更新：**针对这一条路径，它再进一步拆解，交替地估计时延、然后是角度、然后是多普勒。通过多次循环迭代，最终让所有参数收敛到局部最优解。
- **在感知中的应用：**
 - SAGE 是处理多径效应 (MPC) 最经典的算法之一。
 - **优点：**将高维度的非线性优化问题降阶为多个低维度的优化问题，大大降低了计算复杂度。
 - **与 EM 算法的区别：**EM 算法是一次更新所有参数，而 SAGE 是逐个或逐组更新，收敛速度通常比传统的 EM 算法更快。

3. 它们的作用

如果你按照之前梳理的结构写作，MLE 和 SAGE 应该放在**“参数估计”**这一章：

1. **目标函数 (The Goal)：**使用 **MLE** 作为准则，追求达到 **CRLB** 的估计精度。
2. **具体算法 (The Tool)：**使用 **SAGE** 作为实际执行的算法，从复杂的 $H(t, f)$ 叠加信号中剥离出每一条路径的物理特征。

[!NOTE]

论文WiShield: Privacy against Wi-Fi Human Tracking中

MLE + SAGE (AoA/ToF/DFS 等)

这一部分是“把恢复 CSI 转化为可用感知参数”的理论基础，属于 Wi-Fi 感知经典链路。

10.1 多径参数向量与 MLE (论文 Eq. (18)(19))

每条径参数：

$$\theta_l = (\alpha_l, \tau_l, \phi_l, f_{D,l})$$

分别表示：衰落、ToF、AoA、Doppler (DFS)

整体参数：

$$\Theta = (\theta_l)_{l=1}^L$$

对 CSI 向量 $h(m)$ 的对数似然（论文写成负平方误差形式）：

$$\Lambda(\Theta; h) = - \sum_m \left\| h(m) - \sum_{l=1}^L P_l(m; \theta_l) \right\|^2 \quad (18)$$

MLE：

$$\hat{\Theta}_{ML} = \arg \max_{\Theta} \Lambda(\Theta; h) \quad (19)$$

难点：非线性 + 维度高（4L）→ 无闭式解。

10.2 用 SAGE 降维迭代（论文 Eq. (20)(21)(22)）

SAGE 思想：每次只更新某一路径的参数，其他路径保持。

对第 l 条径的“分离信号”：

$$\hat{P}_l(m; \hat{\Theta}') = P_l(m; \hat{\theta}'_l) + \beta_l \left(h_m - \sum_{l'=1}^L P_{l'}(m; \hat{\theta}'_{l'}) \right) \quad (20)$$

随后依次最大化得到：

- $\hat{\tau}_l$ 、 $\hat{\phi}_l$ 、 $\hat{f}_{D,l}$
- 最后算 $\hat{\alpha}_l$

论文用一个匹配函数 $z(\cdot)$ ：

$$\hat{\tau}_l = \arg \max_{\tau} z(\tau, \hat{\phi}_l, \hat{f}_{D,l}; \hat{P}_l)$$

其中：

$$z(\tau, \phi, f_D; P_l) = \sum_m e^{2\pi\Delta f j \tau_l} e^{2\pi f_c \Delta s_k \cdot \phi_l} e^{-2\pi f_{D,l} \Delta t_l} P_l(m) \tag{22}$$

这部分说明：WiShield 不仅“防攻击”，还要让合法用户能继续做 AoA/ToF/DFS 的下游任务（定位/跟踪）。

通信感知隐私权衡

感知质量指标（优化目标（结合数学建模），衡量指标）

指标建模（属于“信号统计量 + 目标函数构造”）

论文为了把“感知可用性/隐私泄露”可优化地量化，引入/使用：

- **SNR（通信侧/感知侧基础指标）**
- **SDNR（Signal-to-Distortion-plus-Noise Ratio）**：把“加密引入的失真”作为分母项，与噪声/静态分量共同构成“对感知有害的因素”，用于度量加密后 CSI 的“可感知性”。

SDNR 是这篇论文非常关键的“桥梁指标”：

- 让“隐私破坏程度/感知质量”能被同一个可计算量度描述，从而进入优化框架。

[!NOTE]

针对文献WiShield: Privacy against Wi-Fi Human Tracking具体分析

“通信里的 SNR”

在通信中，**SNR（Signal-to-Noise Ratio）**回答的是：

“接收端用于解调的数据符号，有多大比例是‘有用信号’，多大比例是‘干扰/噪声’？”

经典形式：

$$\text{SNR}_{\text{comm}} = \frac{\text{signal power}}{\text{noise power}}$$

- signal：承载比特的调制信号

- noise：热噪声、干扰
- SNR 高 $\Rightarrow$ BER 低 $\Rightarrow$ 通信质量好

通信 SNR 的核心任务：能不能把比特判对

“感知”在“判什么”？

Wi-Fi 感知并不关心比特是否正确，它关心的是：

“信道里与人体/目标相关的变化，是否能从背景中被分辨出来？”

也就是说：

- 感知的“信号” $\neq$ 调制符号
- 感知的“噪声/干扰” $\neq$ 只有热噪声

感知里真正有用的是：

“人体运动引起的 CSI 变化”

论文“借用 SNR 的形式来衡量感知质量”

感知问题本质上是一个“检测/估计问题”

不管是：

- 手势识别
- 呼吸监测
- 轨迹跟踪

本质都在问：

“动态变化（人）能不能从背景中被检测/估计出来？”

这是一个统计检测问题，而在统计检测里，SNR 是最经典、最通用的可分性指标。

论文对“感知 SNR”的重新定义

论文明确区分了三类东西：

类别	物理含义
动态分量 h^D	人体运动导致的 CSI 变化（感知真正要用的“信号”）
静态分量 h^S	墙体、家具等背景反射（感知的“干扰”）
噪声 σ^2	接收噪声

于是作者定义：

$$\eta_S = \frac{|h^D|^2}{|h^S|^2 + \sigma^2}$$

你可以把它直译为：

“人体引起的变化能量 / （环境背景 + 噪声）”

这就是**感知版的 SNR**。

和通信 SNR 的“相同点”和“根本不同点”

相同点（为什么还能叫 SNR）

- 都是 “**有用信息 / 干扰信息**”
- 都衡量“**区分能力**”
- 在统计检测理论里都直接影响错误率

根本不同点

维度	通信 SNR	感知 SNR（论文中的）
Signal	调制符号	人体动态引起的 CSI 变化
Noise	热噪声/干扰	静态背景 + 噪声
目标	判比特	判“有没有人/怎么动”
高 SNR 意味着	BER 低	感知/攻击更容易

维度	通信 SNR	感知 SNR（论文中的）
使用场景	解调	检测/估计

所以它们**数学形式像，但语义不同**。

一定要用“类似 SNR 的指标”？

这是一个**工程 + 理论折中**：

1. 可解释性强

一眼就能看出：

- 动态越强 → 感知越容易
- 背景越强 → 感知越困难

2. 可优化

SNR/SDNR 可以直接放进目标函数

$$\max / \min \eta_{SD}$$

这对多目标优化（隐私 vs 感知 vs 通信）非常友好。

3. 与大量感知模型高度相关

不论是：

- PCA/LDA
- CNN/LSTM
- MLE/SAGE

它们的性能最终都与“动态信息相对于背景/噪声的强弱”高度相关。

引入 SDNR

你如果继续用 η_S ：

- 加密后的 CSI 可能：
 - 动态项还在
 - 但结构已经被“人为破坏”

光有“动态能量”不够，还要考虑“失真”

于是定义：

\$\$

η_{SD}

$= \frac{|\hat{h}^D|^2}{\underbrace{|\hat{h} - h|^2}_{\text{加密失真}}}$

- $|\hat{h}^S|^2 + \sigma^2$

\$\$

- 把“隐私保护的代价”显式地引入分母
- 让“攻击难度”和“感知可用性”第一次能用**同一个标量**来度量

问：为什么不用互信息和CRLB

针对隐私和感知和通信的权衡

这些是“选择/优化加密矩阵 Ψ 以平衡隐私与性能”的方法：

- **多目标优化 (Multi-objective optimization)**：同时考虑
 - 降低 Eve 的可感知信息质量（隐私/攻击成功率指标）
 - 保证 BobS 的感知质量
 - 保证 BobC 的通信质量
- **加权标量化 (Weighted-sum scalarization)**：把多目标转成一个加权目标函数（权重 ω_i ）。
- **ADMM (Alternating Direction Method of Multipliers)**：用分裂 + 交替更新的方式求解带约束的（通常是非凸/难直接解）问题。

我们需要构建通信感知隐私指标在过程中进行多目标优化

[!NOTE]

文章WiShield: Privacy against Wi-Fi Human Tracking**不是随便加密，而是求最优加密矩阵 Ψ** 。

多目标优化模型（论文 Eq. (12)(13)(14)）

以 Ψ 为决策变量：

$$\max_{\Psi} \left[-\eta_{SD}^{Eve}, \eta_C^{Bob}, \eta_{SD}^{Bob} \right] \quad (12)$$

约束 1：发射功率（或矩阵能量）约束：

$$\|\Psi\|_2^2 \leq MQ_{Tx} \quad (13)$$

约束 2：合法用户性能下限：

$$\eta_C^{Bob} \geq \epsilon_C, \quad \eta_{SD}^{Bob} \geq \epsilon_{SD} \quad (14)$$

通信 SNR (BobC) 与感知 SDNR (BobS) 定义 (论文 Eq. (15) (16))

通信用户 BobC 的 SNR：

$$\eta_C^{Bob} = \frac{\|\hat{H}\|_2^2}{\sigma^2} \quad (15)$$

感知用户 BobS 的 SDNR (论文给出“解密后”形式，包含残余失真项)：

$$\eta_{SD}^{Bob} = \frac{1}{Q_{Tx}M} \frac{\|\tilde{H}^D\|_2^2}{\|\Psi_q^{-1}\sigma\|_2^2 + \|\tilde{H}^S\|_2^2 + \sigma^2} \quad (16)$$

解释：

- $\tilde{H}^S, \tilde{H}^D$ ：Bob 解密后得到的静态/动态分量
- $\|\Psi_q^{-1}\sigma\|_2^2$ ：解密后的“残余失真”(说明加密不可逆、只能尽量补偿)

标量化加权目标 + ADMM 求解 (论文 Eq. (17))

把多目标转成加权和：

$$\max_{\Psi} \omega_1 \eta_C^{Bob} + \omega_2 \eta_{SD}^{Bob} - \omega_3 \eta_{SD}^{Eve} \quad (17)$$

其中 $\sum_i \omega_i = 1, \omega_i \in [0, 1]$

论文采用 **ADMM (Alternating Direction Method of Multipliers)** 寻找非凸问题的局部最优，并用随机初始化多组 Ψ 做验证，结果显示：

- Eve 侧相关性更低 (更难恢复)
- BobS 侧相关性更高 (更接近原 CSI)
- BobC 的 BER 更低 (通信更好)

补充关于HUAWEI文献（后续增补进前面部分形成体系）

ISAC 的实现方案

SAPE 方案

SAPE 的核心出发点在于**多径传播的利用**。传统通信与定位系统往往将多径视为干扰，而 SAPE 通过引入**虚拟发射点（virtual Transmission Point, vTP）**的概念，将由反射面和散射体产生的非视距路径等效为来自虚拟位置的“有效发射源”，从而将多径转化为可利用的几何信息。

具体而言，SAPE 可通过**两步感知**的方式实现：

1. 通过较宽波束和较低分辨率的扫描构建环境的粗略射频地图；
2. 在已知环境先验和粗定位结果的基础上，对特定子空间进行精细感知，并不断修正 vTP 与地图参数。

回归现实，在动态场景中，行人或车辆产生的临时反射路径可能被误解释为稳定环境结构，产生错误的 vTP，从而导致射频地图污染和系统性能退化。因此，一个关键问题在于：

如何在动态环境中构建具有强大鲁棒性的射频地图？

高频段利用与虚拟孔径成像

毫米波与太赫兹频段具备**超大带宽和短波长**，根据相关分辨率公式可提供更高的距离分辨率。在 ISAC 系统中，高频信号既承担高速通信任务，也被用于精细环境探测。

受限于终端尺寸与功耗，实际系统通常采用**虚拟孔径技术**。其基本思想是：

- 构造一个虚拟 MIMO 天线阵列结构以形成虚拟孔径；
- 采用稀疏扫描方法，将时域和空域的自由度转换为较大的虚拟孔径；
- 该虚拟孔径可以实现与其等效物理孔径相同的性能。

然而，高频虚拟孔径成像对系统误差高度敏感。扫描轨迹不规则、相位噪声以及阵列不匹配等因素都会破坏相干处理条件，导致明显的伪影与旁瓣。

因此，高频 ISAC 系统的感知能力并非仅由带宽或波长决定，而在很大程度上受系统误差影响。若以此作为研究方向，需要重点关注：

在不同应用场景下，哪些误差源对成像与感知性能起主导作用？系统设计应优先约束哪些不确定因素？

信息论视角下的 ISAC

容量-失真（Capacity-Distortion）Tradeoff

在最简单的单用户、无记忆场景下，ISAC 问题可以通过**容量-失真函数**进行刻画。该函数描述了在满足给定感知精度约束的前提下，系统所能实现的最大通信速率。

由此可以看出，通信速率与感知精度之间存在不可避免的权衡关系：

- 当系统提高状态估计精度时，输入信号的自由度受到限制，从而压缩通信速率空间；
- 反之，若系统以通信速率最大化为目标，感知性能也将随之退化。

感知状态与信道状态相关时的扩展建模

在更贴近实际环境的建模中，用于感知的状态变量与通信信道状态往往并不完全一致，但二者具有统计相关性。

在这一条件下，系统需要同时面对：

- 状态相关性带来的潜在增益；
- 不完美信道信息导致的性能敏感性。

状态相关性一方面为联合设计提供了可能的性能提升空间，另一方面也使系统对统计建模的准确性更加依赖。

I-MMSE 关系

在高斯信道条件下，通信信息量与最小均方估计误差（MMSE）之间存在直接联系，即：

$$\frac{d}{d\text{SNR}} I(\text{SNR}) = \frac{1}{2} \text{MMSE}$$

这一关系表明，通信优化与感知优化在一定条件下并非对立目标，而是可以通过统一的数学框架进行协调。

需要注意的是，该联系的成立依赖于特定的信道和噪声假设。当系统偏离理想高斯模型时，这种关系是否仍然成立，以及如何推广到更一般的场景，仍有待进一步探讨。

多用户 ISAC

在多用户 ISAC 场景中，用户间的干扰既可能限制通信性能、影响解码过程，也可能为感知提供额外的信息来源。

通过引入用户间的协作或利用回波作为反馈信息，系统在一定条件下能够同时提升通信速率和感知精度。因此，多用户干扰在通信感知一体化框架下并非必然是负面因素，而可能成为有价值的感知资源。

ISAC 面临的核心技术挑战

ISAC 系统的目标是**通过一个系统同时处理通信与感知任务**，这对现有技术提出了非常高的要求。

ISAC 的挑战可以归纳为以下几个方面：

- **信号设计与优化**：如何设计既能满足通信需求，又能满足感知精度要求的信号？
- **硬件支持**：现有硬件是否能够支持ISAC的高效运行？
- **干扰管理**：如何处理感知信号与通信信号之间的干扰？
- **协同优化**：如何在有限资源下优化通信和感知的同时执行？

信号与波形设计的挑战

如何设计一个“兼容”信号？

在 ISAC 系统中，通信和感知共享同一频谱资源和硬件平台，因此**信号设计**变得至关重要。常见的问题包括：

- **波形设计**：通信信号的设计通常侧重于最大化数据传输率，而感知信号需要优化检测精度（比如目标的定位精度、目标的运动感知精度等）。
- **频谱冲突**：通信与感知的信号不能互相干扰，如何在设计中兼顾两者的需求？

- **高带宽需求**：ISAC 需要较宽的频带来提高通信速率，同时也需要高分辨率的信号来进行精确感知。如何平衡这两者？
- **波形共享**：传统的通信信号（如 OFDM）虽然适用于高速数据传输，但它们的设计并不一定适合感知任务。

如何解决？

- **联合波形设计**：理论上，可以设计一个**联合优化的波形**，既能满足高效的通信需求，又能通过**频域复用**和**时域复用**来增强感知的信号。

硬件与设备挑战

硬件支持：如何实现低成本、高效的 ISAC？

ISAC 的核心在于 **硬件平台的共享**，例如同一套 WiFi 路由器用于通信和感知任务。然而，现有的硬件常常面临以下问题：

- **硬件非理想性**：很多商用设备（如 WiFi 路由器）并不完全适合精确的感知任务。比如，现有的 **WiFi 天线阵列** 不够大，导致无法进行高精度的空间定位。
- **设备协同**：ISAC 通常需要多个设备协同工作（如多个天线/传感器），如何实现多设备的同步并优化它们之间的协作？
- **低成本设计**：商用硬件通常不支持专用的感知任务，如何通过**软硬件协同设计**，在不增加硬件成本的情况下提升系统的感知能力？
- **设备同步问题**：多个设备（如 WiFi 路由器与传感器）如何高效地同步，避免误差的累积影响感知结果？

自干扰抑制与多任务处理

自干扰抑制

ISAC 系统必须面对 **自干扰抑制（Self-interference Cancellation）** 的挑战。当感知和通信信号共用频谱和硬件时，信号间的干扰会影响感知系统的准确性。

- 挑战：
 - **通信与感知信号的相互干扰**：ISAC 设计需要处理这种相互影响，确保通信信号不会破坏感知任务的数据精度，反之亦然。
 - **干扰管理**：尤其是在高密度环境中，如何动态分配通信与感知资源，避免干扰？

多任务处理

ISAC 系统需要同时执行 **多个任务**（如通信、检测、估计、分类）。这要求系统能够进行 **高效的资源分配与任务调度**，在 **多任务并行** 的情况下保证通信和感知的准确性。

- 挑战：
 - **任务调度**：如何智能地调度计算资源，确保通信任务与感知任务之间的互不干扰，并在必要时进行资源复用？